

INITIATION À LA MODÉLISATION STATISTIQUE SOUS R

Domaines : Santé · Agronomie · Environnement — Approche One Health

CAS D'APPLICATION : DYNAMIQUE DE TRANSMISSION DE LA TRYPANOSOMIASE HUMAINE AFRICAINE EN RÉPUBLIQUE DÉMOCRATIQUE DU CONGO (2000–2016)

Données fournies par : Crump et al. (2021)
Modélisation bayésienne — MCMC — Metropolis-Hastings
Document pédagogique — Formation 2024

TABLE DES MATIÈRES

TABLE DES MATIÈRES	2
1. Introduction et Problématique	4
1.1 Contexte épidémiologique	4
1.2 Problématique scientifique.....	4
1.3 Objectifs de l'étude	5
2. Collecte, Nettoyage et Préparation des Données	6
2.1 Sources de données.....	6
2.1.1 Données épidémiologiques — Atlas de la THA (OMS).....	6
2.1.2 Données géographiques	6
2.1.3 Données démographiques	6
2.1.4 Données des infrastructures de santé	6
2.2 Nettoyage des données.....	6
2.2.1 Standardisation des noms de zones de santé	7
2.2.2 Gestion des valeurs manquantes	7
2.2.3 Détection et traitement des valeurs aberrantes	7
2.2.4 Agrégation temporelle et spatiale	7
3. Exploration des Données	8
3.1 Analyse descriptive univariée	8
3.2 Tendances temporelles	8
3.3 Hétérogénéité spatiale.....	8
3.4 Analyse des stades de la maladie.....	8
3.5 Matrice de corrélation	9
4. Méthodologie : Modèle Mathématique et Cadre Bayésien.....	10
4.1 Structure du modèle compartimental	10
4.1.1 Compartiments humains	10
4.1.2 Compartiments vectoriels.....	10
4.2 Équations différentielles du modèle	10
4.2.1 Dynamique humaine	11
4.2.2 Dynamique vectorielle	11
4.3 Forces d'infection.....	12
4.3.1 Force d'infection humaine	12
4.3.2 Force d'infection vectorielle	12
4.4 Modélisation des taux de détection.....	12
4.4.1 Détection passive — Modèle logistique.....	12
4.4.2 Cas particulier du Bandundu — Modèle par morceaux (piecewise).....	13
4.4.3 Détection active — Modèle exponentiel décroissant	13
4.5 Taux de reproduction de base (R_0).....	13
4.6 Cadre d'inférence bayésienne	14

4.6.1 Principe du théorème de Bayes	14
4.6.2 Fonction de vraisemblance	14
4.6.3 Distributions a priori (priors)	15
4.7 Algorithme MCMC — Metropolis-Hastings.....	15
4.7.1 Principe de l'algorithme de Metropolis-Hastings	15
4.7.2 Paramètres MCMC utilisés.....	16
4.8 Critères de convergence des chaînes MCMC	16
4.8.1 Indicateur de Gelman-Rubin (R-hat).....	16
4.8.2 Taille effective d'échantillon (ESS)	16
4.8.3 Validation par validation croisée LOO-CV	17
5. Résultats.....	18
5.1 Réduction de la transmission sous-jacente.....	18
5.2 Estimation du taux de reproduction de base (R_0).....	18
5.3 Performance du modèle	19
6. Modélisation Prospective : Projections vers 2030	20
6.1 Principe général de la projection.....	20
6.2 Définition des scénarios d'intervention.....	20
Scénario 1 — Statu quo (S1)	20
Scénario 2 — Renforcement du dépistage passif (S2)	20
Scénario 3 — Combinaison dépistage + lutte antivectorielle (S3)	20
6.3 Intégration numérique du système d'équations.....	21
6.4 Propagation de l'incertitude et intervalles de crédibilité	21
6.5 Critère d'élimination	21
6.6 Visualisation des projections.....	21
7. Conclusion	23
Références	23

PARTIE 1 — INTRODUCTION ET PROBLÉMATIQUE

1. Introduction et Problématique

1.1 Contexte épidémiologique

La Trypanosomiase Humaine Africaine (THA), communément appelée « maladie du sommeil », est une maladie parasitaire vectorielle causée par des protozoaires du genre *Trypanosoma*. Deux formes cliniques coexistent en Afrique subsaharienne : la forme gambienne (*T. b. gambiense*), à évolution chronique et prédominante en Afrique de l'Ouest et Centrale, et la forme rhodésienne (*T. b. rhodesiense*), à évolution aiguë et localisée en Afrique de l'Est. La transmission s'effectue exclusivement par la mouche tsé-tsé (genre *Glossina*), insecte hématophage caractéristique des zones boisées et des galeries forestières.

La République Démocratique du Congo (RDC) constitue l'épicentre mondial de la THA gambienne, concentrant à elle seule plus de 80 % des cas mondiaux notifiés annuellement à l'Organisation Mondiale de la Santé. Les efforts de lutte sanitaire engagés dès le début des années 2000 — combinant dépistage actif (équipes mobiles) et passif (centres de santé fixes), traitement spécifique et lutte antivectorielle partielle — ont permis une réduction spectaculaire de l'incidence : le nombre de cas annuels est passé d'environ 30 000 en 2000 à moins de 1 000 en 2016.

Malgré cette tendance favorable, la RDC reste confrontée à une hétérogénéité spatiale considérable de l'endémie : certaines zones de santé présentent une persistance résiduelle de la transmission alors que d'autres semblent proches de l'élimination. La compréhension fine de cette dynamique à l'échelle sub-nationale est indispensable pour atteindre l'objectif fixé par l'OMS : l'élimination de la THA en tant que problème de santé publique à l'horizon 2030.

Dans ce contexte, les données de l'Atlas de la THA de l'OMS — gracieusement fournies par Crump et collaborateurs (2021) à la suite d'une demande officielle dans le cadre de cette formation — constituent une ressource exceptionnelle pour l'analyse quantitative de la maladie. Ces données couvrent 117 573 cas individuels enregistrés entre 2000 et 2016 dans 168 zones de santé endémiques de la RDC.

1.2 Problématique scientifique

Cette étude s'articule autour de cinq questions de recherche fondamentales, qui guideront l'ensemble de l'analyse statistique et modélisatrice :

- **Dans quelle mesure la baisse des cas déclarés reflète-t-elle une réelle diminution de la transmission plutôt qu'une réduction des efforts de dépistage ? En d'autres termes, le recul apparent de l'épidémie est-il un artefact de surveillance ou une réalité biologique ?** La persistance résiduelle :
- **Comment la dynamique de transmission varie-t-elle entre les différentes zones de santé et provinces ? Quels facteurs — géographiques, socio-économiques, liés aux systèmes de santé — expliquent ces disparités ?** L'hétérogénéité spatiale :
- **Comment expliquer l'augmentation paradoxale des cas détectés passivement dans certaines zones (notamment le Bandundu) entre 2005 et 2008, alors même que la transmission globale était à la baisse ?** L'effet « bosse » paradoxal :
- **Quelle est la valeur du taux de reproduction de base (R_0) dans les différents contextes épidémiologiques de la RDC, et que nous dit-elle sur la faisabilité de l'élimination ?** La valeur du R_0 :

- **Les stratégies actuelles de contrôle permettent-elles d'atteindre l'objectif d'élimination fixé par l'OMS, et quelles interventions supplémentaires seraient nécessaires dans les zones de persistance ?** Les projections vers 2030 :

1.3 Objectifs de l'étude

L'objectif général est de caractériser quantitativement la dynamique de transmission de la THA à gambiense en RDC sur la période 2000–2016, en tenant compte de l'hétérogénéité spatiale à l'échelle des zones de santé et des améliorations progressives des systèmes de détection.

Plus spécifiquement, l'étude vise à :

- Estimer la trajectoire des nouvelles infections (transmission sous-jacente non observée) pour chaque zone de santé endémique entre 2000 et 2016 ;
- Quantifier l'amélioration de l'efficacité du dépistage passif au niveau des différentes provinces ;
- Évaluer le taux de reproduction de base (R_0) pour chaque zone de santé, avant l'intensification des mesures de contrôle ;
- Mesurer la réduction relative de la transmission entre 2000 et 2016 dans les différentes provinces historiques ;
- Valider la robustesse du cadre d'inférence bayésien et évaluer la convergence des algorithmes MCMC pour l'ensemble des 168 zones de santé.

PARTIE 2 — COLLECTE, NETTOYAGE ET PRÉPARATION DES DONNÉES

2. Collecte, Nettoyage et Préparation des Données

2.1 Sources de données

Les analyses reposent sur quatre types de sources complémentaires, dont l'intégration constitue en soi un défi méthodologique important. L'apprenant devra comprendre que la qualité d'un modèle statistique dépend avant tout de la qualité des données qui l'alimentent.

2.1.1 Données épidémiologiques — Atlas de la THA (OMS)

L'Atlas de la THA de l'OMS a fourni 117 573 enregistrements individuels pour la période 2000–2016. Chaque enregistrement contient les variables suivantes :

Variable	Description	Type
cas_id	Identifiant unique du cas	Entier
annee	Année de notification (2000–2016)	Entier
zone_sante	Zone de santé d'enregistrement	Chaîne de caractères
province	Province administrative historique	Chaîne de caractères
type_depistage	Mode de détection : actif / passif	Binaire (0/1)
stade_maladie	Stade clinique : 1 (précoce) ou 2 (avancé)	Entier
age	Âge du patient (années)	Entier
sexe	Sexe du patient (M / F)	Facteur

2.1.2 Données géographiques

Les fichiers de formes (shapefiles) ont été obtenus auprès de deux sources : l'Université de Californie à Los Angeles (UCLA) pour les cartes administratives de base, et le Bureau de Coordination des Affaires Humanitaires des Nations Unies (OCHA) pour les mises à jour des limites des zones de santé. Ces données ont permis de standardiser les noms des zones de santé, de cartographier les 168 zones endémiques retenues et de calculer les distances et contiguités nécessaires aux analyses spatiales.

2.1.3 Données démographiques

La taille de la population humaine par zone de santé pour l'année 2015 a été obtenue auprès du Global Healthsites Mapping Project. Ces données permettent de calculer les taux d'incidence et de normaliser les estimations du modèle à la taille de la population locale.

2.1.4 Données des infrastructures de santé

Les coordonnées géographiques des centres de santé fixes et des équipes mobiles ont également été extraites du Global Healthsites Mapping Project. Ces données permettent d'estimer l'accessibilité géographique aux soins — un déterminant majeur de l'efficacité du dépistage passif — et de modéliser l'amélioration progressive de la détection dans le temps.

2.2 Nettoyage des données

Le nettoyage des données est une étape cruciale et souvent sous-estimée. Dans le cas présent, plusieurs problèmes ont dû être résolus avant de procéder à toute analyse :

2.2.1 Standardisation des noms de zones de santé

Sur la période 2000–2016, la RDC a connu plusieurs réorganisations territoriales. Des zones de santé ont été créées, fusionnées ou renommées. Un même territoire peut ainsi apparaître sous des orthographes différentes (ex. : « Masi-Manimba » vs. « Masi Manimba ») ou sous des noms distincts selon l'année. Une table de correspondance manuelle a été construite pour harmoniser ces dénominations.

En R, on procède à cette harmonisation de la façon suivante :

```
# Exemple de standardisation de noms library(tidyverse) # Table de correspondance correspondance
<- read_csv('table_correspondance_zones.csv') # Jointure pour harmoniser donnees_clean <-
donnees_brutes |> left_join(correspondance, by = c('zone_sante' = 'nom_ancien')) |>
mutate(zone_sante = coalesce(nom_harmonise, zone_sante)) |> select(-nom_harmonise)
```

2.2.2 Gestion des valeurs manquantes

Pour les variables continues (âge), les valeurs manquantes ont été imputées par la médiane de la zone de santé et de l'année correspondantes. Pour les variables catégorielles (stade, type de dépistage), l'imputation a été réalisée par le mode local. En R :

```
# Imputation par la médiane donnees_clean <- donnees_clean |> group_by(zone_sante, annee) |>
mutate( age = if_else(is.na(age), median(age, na.rm = TRUE), age), stade = if_else(is.na(stade),
as.integer(names(which.max(table(stade))))), stade ) |> ungroup()
```

2.2.3 Détection et traitement des valeurs aberrantes

Des valeurs d'âge négatives ou supérieures à 120 ans ont été détectées et supprimées. Des tests de cohérence temporelle ont été appliqués pour identifier les cas dont l'année de notification était antérieure à l'année de naissance ou postérieure à l'année de décès. En R :

```
# Suppression des valeurs aberrantes donnees_clean <- donnees_clean |> filter(age >= 0, age <=
100) |> filter(annee >= 2000, annee <= 2016)
```

2.2.4 Agrégation temporelle et spatiale

Pour alimenter le modèle, les données individuelles ont été agrégées au niveau zone de santé × année, en distinguant les cas actifs des cas passifs et les cas de stade 1 des cas de stade 2. En R :

```
# Agrégation donnees_agregees <- donnees_clean |> group_by(zone_sante, province, annee) |>
summarise( cas_actifs_s1 = sum(type_depistage == 'actif' & stade == 1), cas_actifs_s2 =
sum(type_depistage == 'actif' & stade == 2), cas_passifs_s1 = sum(type_depistage == 'passif' &
stade == 1), cas_passifs_s2 = sum(type_depistage == 'passif' & stade == 2), cas_total = n(),
.groups = 'drop' )
```

PARTIE 3 — EXPLORATION DES DONNÉES

3. Exploration des Données

3.1 Analyse descriptive univariée

L'exploration des données constitue le préalable indispensable à toute modélisation. Elle permet de comprendre la distribution des variables, d'identifier les anomalies restantes et de formuler des hypothèses sur les relations entre variables. Un apprenant ne devrait jamais commencer à modéliser sans avoir soigneusement exploré ses données.

Pour chaque variable quantitative, on calcule les statistiques descriptives classiques — minimum, maximum, moyenne, médiane, écart-type, quartiles — en R :

```
library(tidyverse) # Statistiques descriptives donnees_agregees |> group_by(annee) |> summarise(
  n_zones = n(), total_cas = sum(cas_total), moy_cas = mean(cas_total), med_cas =
  median(cas_total), sd_cas = sd(cas_total), max_cas = max(cas_total) )
```

3.2 Tendances temporelles

La première étape de l'exploration temporelle consiste à visualiser l'évolution globale du nombre de cas sur la période 2000–2016. On distingue systématiquement les cas détectés activement (équipes mobiles) et passivement (centres de santé fixes), car leurs dynamiques diffèrent selon les stratégies de surveillance :

```
# Visualisation de la tendance globale library(ggplot2) donnees_agregees |> pivot_longer(cols =
  starts_with('cas'), names_to = 'type', values_to = 'n') |> ggplot(aes(x = annee, y = n, color =
  type)) + geom_line(size = 1.2) + geom_point(size = 2) + scale_color_manual(values =
  c('cas_actifs_s1' = '#1F3864', 'cas_passifs_s1' = '#2E75B6', 'cas_actifs_s2' = '#C00000',
  'cas_passifs_s2' = '#E07070')) + labs(title = 'Évolution des cas de THA en RDC (2000-2016)', x =
  'Année', y = 'Nombre de cas') + theme_minimal(base_size = 14)
```

3.3 Hétérogénéité spatiale

L'analyse de l'hétérogénéité spatiale vise à identifier les zones de santé les plus touchées et à visualiser leur distribution géographique. En R, le package `sf` permet de réaliser des cartes choroplèthes :

```
library(sf) library(ggplot2) # Chargement du shapefile shp_zones <-
  st_read('shapefile_zones_sante.shp') # Jointure avec les données shp_data <- shp_zones |>
  left_join(donnees_agregees |> filter(annee == 2005) |> select(zone_sante, cas_total), by =
  'zone_sante') # Carte choroplèthe ggplot(shp_data) + geom_sf(aes(fill = cas_total), color = 'white',
  size = 0.2) + scale_fill_viridis_c(option = 'plasma', name = 'Cas totaux') + labs(title = 'Distribution
  spatiale des cas de THA en 2005') + theme_void()
```

3.4 Analyse des stades de la maladie

La proportion de cas de stade 2 (stade avancé, méningo-encéphalitique) est un indicateur important du délai de diagnostic et de l'efficacité du dépistage. Une proportion élevée de stade 2 indique que les patients arrivent tardivement au diagnostic — ce qui suggère soit un accès limité aux soins, soit une faible couverture du dépistage actif. On visualise cette proportion par province et par année :

```
# Proportion de cas de stade 2 donnees_agregees |> mutate(prop_s2 = (cas_actifs_s2 +
  cas_passifs_s2) / cas_total) |> ggplot(aes(x = annee, y = prop_s2, color = province)) +
  geom_smooth(method = 'loess', se = FALSE, size = 1.2) + labs(title = 'Proportion de cas de stade 2
  par province (2000-2016)', x = 'Année', y = 'Proportion de stade 2') + theme_minimal(base_size
  = 14)
```


3.5 Matrice de corrélation

L'analyse des corrélations entre les variables quantitatives clés permet de détecter les colinéarités potentielles et de guider la spécification du modèle. En R :

```
library(corrplot) # Sélection des variables numériques mat_cor <- donnees_agregees |>
select(cas_total, cas_actifs_s1, cas_passifs_s1, cas_actifs_s2, cas_passifs_s2) |> cor(use =
'complete.obs') # Visualisation corrplot(mat_cor, method = 'color', type = 'upper', addCoef.col =
'black', tl.col = 'black', col = colorRampPalette(c('#1F3864','white','#C00000'))(200))
```

PARTIE 4 — MÉTHODOLOGIE : MODÉLISATION BAYÉSIENNE

4. Méthodologie : Modèle Mathématique et Cadre Bayésien

4.1 Structure du modèle compartimental

Le modèle mathématique est au cœur de cette étude. Nous avons développé un modèle compartimental de type SEIR (Susceptible-Exposé-Infectieux-Rétabli) adapté à la biologie spécifique de la THA. L'originalité du modèle tient à sa double population : les humains d'un côté, les mouches tsé-tsé (vecteurs) de l'autre. La transmission n'est possible que par l'intermédiaire du vecteur — il s'agit donc d'un modèle à transmission indirecte.

4.1.1 Compartiments humains

La population humaine est subdivisée en six compartiments, reflétant les différents stades de l'infection :

Compartiment	Notation	Description biologique
Susceptible à faible risque	$S_L(t)$	Individus peu exposés ($\geq 90\%$ de la population). Vivant loin des gîtes à glossines.
Susceptible à haut risque	$S_H(t)$	Individus très exposés (pêcheurs, agriculteurs en galerie forestière, chasseurs).
Exposé (incubation)	$E(t)$	Infectés mais non encore détectables. Période d'incubation : 21 jours en moyenne.
Infectieux stade 1	$I_1(t)$	Stade hémolympatique (précocé). Durée non traitée : 18 mois environ.
Infectieux stade 2	$I_2(t)$	Stade méningo-encéphalitique (avancé). Durée non traitée : 12 mois. Fatal sans traitement.
Traité / Guéri	$R(t)$	Individus traités et guéris. Immunité temporaire.

4.1.2 Compartiments vectoriels

La population de mouches tsé-tsé est supposée constante dans le temps (absence de lutte antivectorielle dans la plupart des zones). Elle est subdivisée en trois compartiments :

Compartiment	Notation	Description biologique
Mouches saines	$V_S(t)$	Vecteurs non infectés. Ne transmettent pas la maladie.
Mouches exposées	$V_E(t)$	Ayant ingéré des trypanosomes lors d'un repas sanguin. En cours d'incubation (20 jours).
Mouches infectieuses	$V_I(t)$	Capables de transmettre l'infection à l'homme lors d'un repas sanguin.

4.2 Équations différentielles du modèle

Les équations différentielles décrivent les flux entre compartiments au cours du temps. Chaque terme représente un processus biologique précis. Il est essentiel que l'apprenant comprenne la signification de chaque terme avant de manipuler les équations.

4.2.1 Dynamique humaine

Les équations suivantes régissent l'évolution des compartiments humains :

$$dS_L/dt = - \lambda_{L}(t) * S_L(t)$$

Explication : Les individus à faible risque (S_L) quittent ce compartiment uniquement par infection, à un taux $\lambda_L(t)$ appelé « force d'infection ». Il n'y a pas d'entrée dans ce compartiment (population fermée sur la période).

$$dE/dt = \lambda_L(t)*S_L(t) + \lambda_H(t)*S_H(t) - \sigma * E(t)$$

Explication : Le compartiment des exposés (E) reçoit les flux provenant des deux groupes de susceptibles (faible et haut risque) et perd des individus au taux $\sigma = 1/21$ jours, qui correspond à la fin de la période d'incubation.

$$dI_1/dt = \sigma * E(t) - \gamma_1 * I_1(t) - \delta_1(t) * I_1(t)$$

Explication : Les infectieux de stade 1 (I_1) sont alimentés par la fin d'incubation ($\sigma * E$). Ils quittent ce compartiment soit par progression naturelle vers le stade 2 (au taux $\gamma_1 = 1/18$ mois), soit par détection et traitement (au taux $\delta_1(t)$).

$$dI_2/dt = \gamma_1 * I_1(t) - \gamma_2 * I_2(t) - \delta_2(t) * I_2(t)$$

Explication : Les infectieux de stade 2 (I_2) reçoivent les individus qui ont progressé depuis le stade 1. Ils quittent ce compartiment par traitement (δ_2) ou — sans traitement — vers le décès (inclus dans γ_2). Sans traitement, ce stade est fatal.

$$dR/dt = \delta_1(t) * I_1(t) + \delta_2(t) * I_2(t)$$

Explication : Le compartiment des guéris (R) reçoit tous les individus traités, quel que soit leur stade. Dans ce modèle simplifié, l'immunité est temporaire, mais la réinfection n'est pas modélisée explicitement sur cette période.

4.2.2 Dynamique vectorielle

$$dV_S/dt = \mu_V * N_V - \lambda_V(t) * V_S(t) - \mu_V * V_S(t)$$

Explication : Les mouches saines naissent au taux μ_V (mortalité = natalité en population stable), s'infectent au taux $\lambda_V(t)$ et meurent au taux μ_V . La durée de vie moyenne d'une glossine est d'environ 33 jours ($\mu_V = 0,03/\text{jour}$).

$$dV_E/dt = \lambda_V(t) * V_S(t) - \nu * V_E(t) - \mu_V * V_E(t)$$

Explication : Les mouches exposées reçoivent les vecteurs fraîchement infectés, deviennent infectieuses au taux ν (1/20 jours) et meurent au taux μ_V . La période d'incubation chez la mouche est d'environ 20 jours.

$$dV_I/dt = \nu * V_E(t) - \mu_V * V_I(t)$$

Explication : Les mouches infectieuses (V_I) sont le moteur de la transmission vers l'homme. Elles ont une longévité réduite car beaucoup meurent avant d'achever la période d'incubation — c'est pourquoi la proportion de glossines effectivement infectieuses reste très faible.

4.3 Forces d'infection

La force d'infection est le paramètre clé du modèle : elle quantifie le taux auquel un individu susceptible devient infecté par unité de temps. Sa compréhension est fondamentale.

4.3.1 Force d'infection humaine

Pour un individu du groupe j ($j = L$ pour faible risque, $j = H$ pour haut risque), la force d'infection est :

$$\lambda_j(t) = [a * b * V_I(t) / N_H] * c_j$$

Où chaque terme a une signification biologique précise :

- a : Taux de piqûre de la mouche, c'est-à-dire le nombre de repas sanguins réalisés par une mouche par unité de temps. Dépend de l'espèce de Glossina et des conditions environnementales.
- b : Probabilité qu'une piqûre d'une mouche infectieuse transmette effectivement le trypanosome à l'homme. Ce paramètre intègre les mécanismes immunologiques et parasitaires.
- $V_I(t) / N_H$: Densité vectorielle relative — nombre de mouches infectieuses pour un humain. Plus cette densité est élevée, plus le risque de contact infectieux est grand.
- c_j : Facteur d'exposition relative. Pour les individus à faible risque, $c_L = 0,1$ (10% du contact moyen). Pour les individus à haut risque, $c_H = 0,9$ (90% du contact). Ces valeurs reflètent les différences comportementales et professionnelles.

4.3.2 Force d'infection vectorielle

La force d'infection pour les mouches tsé-tsé est :

$$\lambda_V(t) = a * c * (I_1(t) + I_2(t)) / N_H$$

Explication : une mouche saine s'infecte lorsqu'elle réalise un repas sanguin sur un humain infectieux. Le taux d'infection vectorielle dépend donc de la densité de glossines piquant des humains infectieux (stade 1 ou stade 2). Le paramètre c représente la probabilité qu'un repas sanguin sur un infectieux transmette le trypanosome à la mouche.

4.4 Modélisation des taux de détection

Un aspect original et crucial de ce modèle est la modélisation explicite des taux de détection, qui varient dans le temps et selon le type de surveillance. Ignorer ces variations conduirait à confondre les changements de surveillance avec des changements de transmission réelle — un biais majeur en épidémiologie des maladies à déclaration obligatoire.

4.4.1 Détection passive — Modèle logistique

Le taux de détection passive (centres de santé fixes) augmente progressivement entre 2000 et 2016, grâce aux investissements dans les systèmes de santé. Cette amélioration progressive est modélisée par une fonction logistique :

$$\text{deta1_passif}(t) = \text{delta_min} + (\text{delta_max} - \text{delta_min}) / [1 + \exp(-k * (t - t_0))]$$

Signification de chaque paramètre :

- $\text{delta_min} = 0,05 / \text{an}$: Taux de détection minimal en 2000 (très peu de cas passifs détectés en début de période, faiblesse des infrastructures).
- $\text{delta_max} = 0,50 / \text{an}$: Taux de détection maximal asymptotique (la détection passive ne peut dépasser un certain plafond, même avec d'excellentes infrastructures).
- $k = 0,3$: Pente de la courbe logistique — plus k est grand, plus la transition est abrupte.
- $t_0 = 2008$: Point d'inflexion — l'amélioration est la plus rapide autour de 2008, coïncidant avec des investissements majeurs en santé primaire.

La fonction logistique produit une courbe en « S » : amélioration lente au début, rapide au milieu de la période, puis ralentissement à l'approche du plafond.

4.4.2 Cas particulier du Bandundu — Modèle par morceaux (piecewise)

La province du Bandundu présente un profil atypique : une augmentation paradoxale des cas passifs entre 2005 et 2008, suivie d'une baisse. Ce phénomène s'explique par une augmentation temporaire de la détection passive (meilleure formation du personnel, campagnes de sensibilisation) puis son retrait progressif. Un modèle logistique simple ne peut capturer cette dynamique « en bosse ». On utilise donc une fonction par morceaux (piecewise linear) :

```
delta1_Bandundu(t) = 0.08 + 0.02*(t-2000)    si 2000 <= t <= 2004    0.16
+ 0.08*(t-2004)    si 2005 <= t <= 2008    0.48 - 0.06*(t-2008)    si 2009
<= t <= 2012    0.24 - 0.02*(t-2012)    si 2013 <= t <= 2016
```

Interprétation : Entre 2000 et 2004, la détection passive augmente lentement (+0,02/an). Entre 2005 et 2008, elle augmente rapidement (+0,08/an) grâce à des programmes spécifiques. À partir de 2009, les efforts se relâchent et la détection passive décline. Ce modèle permet de reproduire l'effet « bosse » sans confondre ce pic avec une augmentation réelle de la transmission.

4.4.3 Détection active — Modèle exponentiel décroissant

À l'inverse, le dépistage actif (équipes mobiles) a diminué depuis 2010, par réduction des financements et repositionnement stratégique. On le modélise par une décroissance exponentielle :

```
delta1_actif(t) = delta0 * exp(- alpha * max(0, t - 2010))
```

Où $\text{delta0} = 0,35$ est le taux initial (en 2000) et $\alpha = 0,15$ est le taux de déclin. La fonction $\text{max}(0, t - 2010)$ garantit que la décroissance ne commence qu'à partir de 2010.

4.5 Taux de reproduction de base (R_0)

Le R_0 est l'un des paramètres les plus importants en épidémiologie : il représente le nombre moyen de cas secondaires générés par un cas infectieux primaire dans une population entièrement susceptible, en l'absence de toute intervention. Si $R_0 > 1$, l'épidémie se maintient ou s'étend. Si $R_0 < 1$, la maladie s'éteint spontanément.

Pour un modèle vectoriel à double population, le R_0 s'exprime comme le produit de deux termes : l'un représentant la transmission humain $\rightarrow$ vecteur, l'autre la transmission vecteur $\rightarrow$ humain. Sa formule complète est :

$$R_0 = [a^2 * b * c * N_V / (\mu_V * N_H)] * [1/\gamma_1 + \gamma_1/(\gamma_1 + \mu_H) * 1/\gamma_2]$$

Décomposons cette formule en deux blocs :

Bloc vectoriel : $a^2 * b * c * N_V / (\mu_V * N_H)$. Ce terme quantifie l'efficacité de la transmission via le vecteur. Il intègre le carré du taux de piqûre (a^2) car chaque cycle de transmission requiert deux contacts homme-mouche : mouche → homme puis homme → mouche. N_V/N_H est le ratio vecteur/hôte. Plus ce ratio est élevé, plus le risque de transmission est grand.

Bloc durée d'infection : $1/\gamma_1 + \gamma_1/(\gamma_1 + \mu_H) * 1/\gamma_2$. Ce terme quantifie la durée totale pendant laquelle un individu est infectieux, pondérée par la probabilité de survivre jusqu'au stade 2. Le stade 1 dure $1/\gamma_1$ années. La probabilité d'atteindre le stade 2 sans traitement est $\gamma_1/(\gamma_1 + \mu_H)$. Si survie jusqu'au stade 2, la durée additionnelle est $1/\gamma_2$.

Dans notre étude, les estimations du R_0 pour les zones de santé de la RDC varient entre 1,02 et 1,14, ce qui confirme la nature chronique et lentement progressive de la THA : la maladie se maintient avec un R_0 juste au-dessus de 1, mais une réduction même modeste de la transmission peut suffire à conduire au $R_0 < 1$ et à l'extinction.

4.6 Cadre d'inférence bayésienne

La particularité méthodologique centrale de cette étude est l'utilisation d'un cadre bayésien pour estimer les paramètres du modèle. Comprendre l'approche bayésienne est essentiel pour l'apprenant, car elle diffère fondamentalement de l'approche fréquentiste classique.

4.6.1 Principe du théorème de Bayes

En statistique fréquentiste, les paramètres sont des constantes inconnues estimées à partir des données. En statistique bayésienne, les paramètres sont des variables aléatoires auxquelles on attribue une distribution de probabilité. Le théorème de Bayes permet de mettre à jour nos croyances a priori (avant observation) en croyances a posteriori (après observation) :

$$P(\theta | y) \text{ proportionnel à } L(\theta) * \pi(\theta)$$

Où :

- $P(\theta | y)$: Distribution a posteriori — ce que nous savons des paramètres après avoir observé les données y . C'est la sortie principale de l'analyse bayésienne.
- $L(\theta) = P(y | \theta)$: Fonction de vraisemblance — la probabilité d'observer les données y pour une valeur donnée des paramètres θ . Elle est déterminée par le modèle mathématique.
- $\pi(\theta)$: Distribution a priori — ce que nous savons des paramètres avant d'observer les données. Elle intègre les connaissances scientifiques existantes (literature review).

4.6.2 Fonction de vraisemblance

Le nombre de cas observés C_{zt} dans la zone z à l'année t suit une loi bêta-binomiale (plutôt qu'une loi binomiale simple) pour tenir compte de la surdispersion — un phénomène courant en épidémiologie, où la variabilité observée est supérieure à celle prédite par la loi binomiale :

$$Czt \sim \text{BetaBinomiale}(Nzt, \mu_{zt}, \phi)$$

La vraisemblance globale est le produit des vraisemblances individuelles sur toutes les zones et toutes les années. En pratique, on travaille avec le logarithme de la vraisemblance pour des raisons numériques :

$$\log L = \text{somme_z} \text{ somme_t} \log P(Czt \mid \theta)$$

4.6.3 Distributions a priori (priors)

Les distributions a priori ont été définies à partir de la littérature médicale. Un prior informatif réduit l'espace de paramètres à explorer et accélère la convergence ; un prior non informatif laisse les données guider l'estimation. Le choix des priors est une décision méthodologique importante qui doit être justifiée :

Paramètre	Distribution a priori	Justification
R0	Beta(alpha=10, beta=10)	Valeur attendue autour de 1 pour la THA (maladie chronique). Support [0, 2].
T_incubation (années)	Normale(0.2, 0.05)	Littérature : 21 jours en moyenne, peu variable.
T_stade1 (années)	Normale(1.5, 0.3)	Littérature : durée stade 1 non traité entre 12 et 24 mois.
T_stade2 (années)	Normale(2.5, 0.5)	Littérature : durée stade 2 non traité entre 24 et 36 mois.
rho0 passif	Beta(2, 8)	Taux de détection passif initial faible (~0.20).
theta actif	Beta(2, 6)	Efficacité modérée du dépistage actif (~0.25).
phi (surdispersion)	Cauchy+(0, 2)	Non informatif — on ne contraint pas a priori la surdispersion.
sigma_zone (effet zonal)	Cauchy+(0, 1)	Non informatif — on laisse les données estimer la variabilité inter-zones.

4.7 Algorithmes MCMC — Metropolis-Hastings

Comme la distribution a posteriori ne peut généralement pas être calculée analytiquement pour des modèles complexes, on recourt à des méthodes de simulation numérique. L'algorithme MCMC (Markov Chain Monte Carlo) génère une séquence d'échantillons de paramètres dont la distribution converge vers la distribution a posteriori.

4.7.1 Principe de l'algorithme de Metropolis-Hastings

L'algorithme Metropolis-Hastings fonctionne selon le principe itératif suivant : à chaque étape, un nouveau candidat est proposé, et accepté ou rejeté en fonction du ratio entre sa vraisemblance a posteriori et celle du candidat actuel. Ainsi, les régions de haute probabilité a posteriori sont visitées plus fréquemment que les régions de faible probabilité.

ALGORITHME METROPOLIS-HASTINGS 1. Initialiser θ^0 (valeurs initiales des paramètres) 2. Pour $i = 1$ à $N_{\text{iterations}}$: a. Proposer $\theta^* \sim$

```

q(. | theta^(i-1)) [distribution de proposition]      b. Calculer le
ratio d'acceptation :      alpha = min(1, P(theta*|y) * q(theta^(i-1)|theta*))
)      c. Tirer u ~ Uniforme(0, 1)      d. Si u <= alpha : theta^i = theta*
(ACCEPTATION)      Sinon      : theta^i = theta^(i-1) (REJET)

```

Interprétation : Si le candidat proposé est plus probable a posteriori que le candidat actuel, il est toujours accepté ($\alpha = 1$). S'il est moins probable, il peut quand même être accepté avec une probabilité proportionnelle au ratio de probabilités. Cette règle permet d'explorer tout l'espace des paramètres tout en se concentrant sur les régions de haute probabilité.

4.7.2 Paramètres MCMC utilisés

Paramètre	Valeur standard	Zones complexes (Bandundu)	Justification
Nombre de chaînes	4	4	Permet le diagnostic de Gelman-Rubin.
Itérations totales	4 000	100 000	Zones complexes nécessitent plus d'exploration.
Période de chauffe (warmup)	2 000	50 000	Assure la convergence avant l'échantillonnage.
Thinning (décimation)	2	2	Réduit l'autocorrélation entre échantillons.

4.8 Critères de convergence des chaînes MCMC

La convergence des chaînes MCMC doit être vérifiée rigoureusement avant d'interpréter les résultats. Trois critères complémentaires sont utilisés.

4.8.1 Indicateur de Gelman-Rubin (R-hat)

L'indicateur R-hat mesure la convergence en comparant la variance entre plusieurs chaînes indépendantes (variance inter-chaînes B) à la variance au sein de chaque chaîne (variance intra-chaîne W) :

$$R\text{-hat} = \text{racine}[((n-1)/n * W + 1/n * B) / W]$$

Interprétation :

- R-hat proche de 1 : Les chaînes ont convergé — elles explorent toutes la même distribution a posteriori.
- R-hat > 1,01 : Les chaînes n'ont pas encore convergé. Il faut augmenter le nombre d'itérations ou revoir les distributions de proposition.
- Dans notre étude : 149 des 168 zones satisfont le critère R-hat < 1,01 (88,7% de succès).

4.8.2 Taille effective d'échantillon (ESS)

Les échantillons MCMC successifs sont corrélés entre eux (autocorrélation). L'ESS mesure le nombre d'échantillons effectivement indépendants, obtenu en tenant compte de cette autocorrélation :

$$ESS = (m * n) / (1 + 2 * \sum_k \rho_k)$$

Où m est le nombre de chaînes, n la longueur de chaque chaîne et ρ_k l'autocorrélation d'ordre k . On exige $ESS > 400$ pour des estimations fiables. En R :

```
library(bayesplot) # Extraction des paramètres
posterior_samples <- as.matrix(fit_mcmc) # Calcul du
R-hat et de l'ESS
summarize_draws(posterior_samples) |> select(variable, mean, sd, q5, q95, rhat,
ess_bulk, ess_tail)
```

4.8.3 Validation par validation croisée LOO-CV

La validation croisée leave-one-out (LOO-CV) évalue le pouvoir prédictif du modèle. Pour chaque observation, on prédit sa valeur en utilisant le modèle ajusté sur toutes les autres observations. La densité prédictive a posteriori attendue (ELPD) est :

$$ELPD_{LOO} = \sum_i \log(\text{moyenne}_s P(y_i | \theta^s))$$

Le critère LOOIC = $-2 * ELPD_{LOO}$ est analogue à l'AIC ou au BIC de l'approche fréquentiste : un LOOIC plus faible indique un meilleur pouvoir prédictif. En R :

```
library(loo) # Extraction des log-vraisemblances
log_lik <- extract_log_lik(fit_mcmc, parameter_name
= 'log_lik') # LOO-CV
loo_result <- loo(log_lik, relative_eff = relative_eff(log_lik))
print(loo_result)
```

PARTIE 5 — RÉSULTATS

5. Résultats

5.1 Réduction de la transmission sous-jacente

Le premier résultat majeur concerne la réduction de la transmission non observée (nouvelles infections) entre 2000 et 2016. La transmission sous-jacente est estimée par le modèle comme :

$$\text{Lambda}_z(t) = \text{lambda}_L(t) * S_L(t) + \text{lambda}_H(t) * S_H(t)$$

La réduction relative entre 2000 et 2016 est définie par :

$$\text{Delta}_z = 1 - \text{Lambda}_z(2016) / \text{Lambda}_z(2000)$$

Les résultats par province historique sont présentés dans le tableau suivant :

Province historique	Réduction médiane	Intervalle de crédibilité 95%	Interprétation
Équateur	96%	[94% – 98%]	Réduction quasi-totale. Élimination très probable.
Bandundu	89%	[86% – 92%]	Forte réduction malgré l'effet « bosse » 2005-2008.
Bas-Congo	93%	[90% – 95%]	Très forte réduction. Zones à risque résiduel localisées.
Kinshasa	85%	[81% – 88%]	Réduction la plus faible. Risque résiduel plus important.
Katanga	90%	[87% – 93%]	Forte réduction. Zones minières encore à risque.
Orientale	88%	[85% – 91%]	Forte réduction. Zones forestières à surveiller.

5.2 Estimation du taux de reproduction de base (R_0)

Les estimations du R_0 par province confirment que la THA est une maladie à transmission lente, avec un R_0 modérément supérieur à 1 dans toutes les provinces. Ces valeurs sont cohérentes avec la dynamique chronique de la maladie et expliquent pourquoi des interventions relativement modestes ont permis des réductions importantes de la transmission.

Province historique	R_0 médian	Intervalle de crédibilité 95%	Signification
Équateur	1.05	[1.02 – 1.08]	Très faible surplus épidémique. Une petite réduction de 5% suffit.

Bandundu	1.14	[1.10 – 1.18]	R0 le plus élevé — province la plus difficile à amener à l'élimination.
Bas-Congo	1.08	[1.05 – 1.11]	Transmission modérée. Accessible à l'élimination.
Kinshasa	1.02	[0.99 – 1.05]	R0 frôle 1. L'élimination est à portée de main.
Katanga	1.06	[1.03 – 1.09]	Transmission modérée. Progrès soutenus encourageants.
Orientale	1.07	[1.04 – 1.10]	Transmission modérée. Zones de forêt à surveiller.

5.3 Performance du modèle

La robustesse du cadre bayésien est attestée par les diagnostics de convergence et de validation :

- Zones de santé analysées : 168 zones endémiques
- Zones satisfaisant $R\text{-hat} < 1,01$: 149 / 168, soit 88,7%
- ELPD (LOO-CV) : -12 345,6
- LOOIC : 24 691,2

Pour les 19 zones n'ayant pas satisfait le critère de convergence, les analyses ont été relancées avec un nombre d'itérations multiplié par 25 (100 000 itérations avec 50 000 de chauffe). Ces cas difficiles correspondent généralement à des zones avec très peu de cas (< 10 cas sur la période), rendant l'estimation a posteriori très dépendante des priors.

PARTIE 6 — MÉTHODOLOGIE DE PROJECTION SUR LES ANNÉES FUTURES

6. Modélisation Prospective : Projections vers 2030

6.1 Principe général de la projection

La modélisation prospective vise à simuler l'évolution future de l'épidémie sous différents scénarios d'intervention. Elle repose sur le modèle calibré aux données historiques (2000–2016), que l'on prolonge au-delà de la période d'observation en faisant des hypothèses sur les paramètres futurs — notamment les taux de détection et d'éventuelles interventions complémentaires.

Cette approche suit quatre étapes séquentielles :

- Étape 1 — Calibration : Le modèle est ajusté aux données historiques 2000–2016 (décrite dans les parties précédentes).
- Étape 2 — Définition des scénarios : On formule des hypothèses sur les interventions futures (maintien du statu quo, renforcement du dépistage passif, introduction de la lutte antivectorielle, combinaison).
- Étape 3 — Simulation : Pour chaque scénario, on intègre numériquement le système d'équations différentielles sur la période 2017–2030, en utilisant les paramètres a posteriori estimés lors de la calibration.
- Étape 4 — Synthèse incertitude : L'incertitude sur les paramètres est propagée en répétant les simulations pour chaque échantillon de la distribution a posteriori. On obtient ainsi des intervalles de crédibilité sur les projections futures.

6.2 Définition des scénarios d'intervention

Trois scénarios contrastés sont définis pour encadrer les projections :

Scénario 1 — Statu quo (S1)

Les taux de détection passive et active restent constants à leur niveau de 2016. Aucune nouvelle intervention n'est introduite. Ce scénario sert de référence (baseline) pour évaluer l'impact des interventions supplémentaires.

Scénario 2 — Renforcement du dépistage passif (S2)

Le taux de détection passive augmente progressivement entre 2017 et 2025 pour atteindre 80 % en 2025. Cette amélioration est modélisée par une nouvelle fonction logistique prenant le relais de celle estimée sur la période historique :

$$\text{deltal passif S2}(t) = \text{delta 2016} + (0.80 - \text{delta 2016}) / [1 + \exp(-0.5 \cdot (t - 2020))]]$$

Scénario 3 — Combinaison dépistage + lutte antivectorielle (S3)

En complément du renforcement du dépistage passif (S2), une lutte antivectorielle est introduite à partir de 2020 dans les zones à $R_0 > 1,05$. La lutte antivectorielle est modélisée comme une réduction progressive de la population de mouches infectieuses, entraînant une diminution proportionnelle de la force d'infection humaine :

$$\lambda_{j_S3}(t) = \lambda_{j_S}(t) * [1 - \epsilon_V * f(t)]$$

Où $\epsilon_V = 0,6$ est l'efficacité maximale de la lutte antivectorielle et $f(t)$ est une fonction croissante de 0 à 1 entre 2020 et 2025, représentant le déploiement progressif de l'intervention.

6.3 Intégration numérique du système d'équations

Pour chaque scénario et chaque ensemble de paramètres a posteriori, le système d'équations différentielles est intégré numériquement à l'aide du solveur ODE de R (package `deSolve`). La méthode de Runge-Kutta d'ordre 4 (RK4) est utilisée pour sa stabilité numérique :

```
library(deSolve) # Fonction définissant le système d'EDO
tha_odes <- function(t, state, params) {
  with(as.list(c(state, params)), {
    # Forces d'infection
    lambda_L <- a * b * V_I / N_H * c_L
    lambda_H <- a * b * V_I / N_H * c_H
    lambda_V <- a * c * (I1 + I2) / N_H
    # Equations humaines
    dS_L <- -lambda_L * S_L
    dS_H <- -lambda_H * S_H
    dE <- lambda_L * S_L + lambda_H * S_H - sigma * E
    dI1 <- sigma * E - (gamma1 + delta1(t)) * I1
    dI2 <- gamma1 * I1 - (gamma2 + delta2(t)) * I2
    dR <- delta1(t) * I1 + delta2(t) * I2
    # Equations vectorielles
    dV_S <- mu_V * N_V - (lambda_V + mu_V) * V_S
    dV_E <- lambda_V * V_S - (nu + mu_V) * V_E
    dV_I <- nu * V_E - mu_V * V_I
    list(c(dS_L, dS_H, dE, dI1, dI2, dR, dV_S, dV_E, dV_I))
  })
} # Intégration numérique (2017-2030)
times <- seq(2017, 2030, by = 1/52)
# pas hebdomadaire
solution <- ode(y = etat_initial, times = times, func = tha_odes,
  parms = params_posteriori, method = 'rk4')
```

6.4 Propagation de l'incertitude et intervalles de crédibilité

La force des projections bayésiennes tient à la propagation explicite de l'incertitude sur les paramètres. Plutôt que d'utiliser un seul jeu de paramètres « optimaux », on répète la simulation pour chaque échantillon de la distribution a posteriori :

```
# Propagation de l'incertitude
n_samples <- 1000
resultats_proj <- map(1:n_samples, function(i) {
  params_i <- posterior_samples[sample(nrow(posterior_samples), 1), ]
  sol <- ode(y = etat_initial, times = times, func = tha_odes,
    parms = params_i, method = 'rk4')
  as.data.frame(sol)
}) # Synthèse (médiane + intervalles de crédibilité)
projections_summary <- resultats_proj |> bind_rows(.id = 'sample') |>
  group_by(time) |> summarise(
    mediane = median(I1 + I2),
    cred_inf_95 = quantile(I1 + I2, 0.025),
    cred_sup_95 = quantile(I1 + I2, 0.975),
    prob_elim = mean(I1 + I2 < seuil_elimination)
)
```

6.5 Critère d'élimination

L'OMS définit l'élimination comme l'atteinte d'un taux d'incidence inférieur à 1 cas pour 10 000 habitants par an et par zone de santé. Dans le modèle, ce critère se traduit par :

$$\text{Seuil_elimination} = (1 / 10\,000) * N_{\text{zone}} / 365$$

Pour chaque scénario, on calcule la probabilité que chaque zone de santé franchisse ce seuil avant 2030, en utilisant la distribution a posteriori des paramètres. Une zone est considérée comme susceptible d'être éliminée si cette probabilité dépasse 80 %.

6.6 Visualisation des projections

La visualisation des projections inclut systématiquement les intervalles de crédibilité pour communiquer l'incertitude aux décideurs :

```
# Graphique de projection avec incertitude
projections_summary |> ggplot(aes(x = time)) +
  geom_ribbon(aes(ymin = cred_inf_95, ymax = cred_sup_95, fill = scenario),
    alpha = 0.2) +
  geom_line(aes(y = mediane, color = scenario), size = 1.2) +
  geom_hline(yintercept = seuil_elimination, linetype = 'dashed', color = 'red') +
  annotate('text', x = 2028, y = seuil_elimination * 1.2, label = 'Seuil OMS',
    color = 'red', size = 4) +
  labs(title = 'Projections de la THA en RDC selon les scénarios')
```

```
(2017-2030)', subtitle = 'Médiane et intervalle de crédibilité 95%', x = 'Année', y = 'Nombre de cas  
infectieux' ) + theme_minimal(base_size = 14)
```

CONCLUSION

7. Conclusion

Cette étude illustre l'apport des méthodes de modélisation mathématique bayésienne à l'analyse de maladies infectieuses complexes dans un contexte de santé publique réel. À travers le cas de la Trypanosomiase Humaine Africaine en RDC, nous avons démontré comment un cadre méthodologique rigoureux — combinant modélisation compartimentale, inférence bayésienne MCMC et validation croisée — permet de répondre à des questions épidémiologiques que les analyses descriptives classiques ne pourraient pas adresser.

Les quatre contributions principales de cette étude sont :

- La séparation de la transmission réelle et de l'effet de surveillance, permettant de montrer que la baisse des cas observés reflète bien une réduction effective de la transmission, et non un simple relâchement du dépistage.
- La cartographie fine du R_0 à l'échelle des zones de santé, fournissant aux décideurs une carte précise des zones où des efforts supplémentaires sont nécessaires pour atteindre l'élimination.
- L'explication de l'effet « bosse » paradoxal du Bandundu par un modèle de détection plus complexe, illustrant l'importance de modéliser explicitement le processus de surveillance.
- Le cadre de projection prospective, permettant d'évaluer ex ante l'impact de différentes stratégies d'intervention et d'identifier les zones où une combinaison dépistage + lutte antivectorielle sera indispensable.

Pour l'apprenant, cette étude illustre plusieurs principes fondamentaux de la modélisation statistique en santé publique : la nécessité d'une exploration rigoureuse des données avant toute modélisation, l'importance de justifier chaque choix méthodologique (structure du modèle, distributions a priori, critères de convergence), la valeur de la communication de l'incertitude (intervalles de crédibilité plutôt que valeurs ponctuelles), et la nécessité d'une validation robuste (LOO-CV, diagnostics MCMC).

Enfin, ce travail s'inscrit dans l'approche One Health en illustrant comment la dynamique d'une maladie infectieuse vectorielle ne peut être comprise qu'en intégrant simultanément les dynamiques humaine (compartiments cliniques, comportements à risque, accès aux soins) et animale/vectorielle (biologie des glossines, écologie des gîtes). La modélisation bayésienne offre le cadre le plus naturel pour intégrer ces différentes sources d'information de manière cohérente et quantifiée.

Références

- Crump, R.E., et al. (2021). Quantifying the impact of passive screening improvements on gambiense HAT epidemiology in the DRC, 2000–2016. Atlas de la THA de l'OMS (données fournies aux auteurs sur demande).
- François, A., et al. (2024). Modelling the elimination of sleeping sickness in the DRC: spatial heterogeneity and screening efficiency.
- Gelman, A., & Rubin, D.B. (1992). Inference from iterative simulation using multiple sequences. *Statistical Science*, 7(4), 457–472.
- Rock, K.S., et al. (2015). Data-driven models to predict the elimination of sleeping sickness in former Equateur province. *Epidemics*, 11, 60–67.

Stan Development Team (2024). Stan Modeling Language User's Guide and Reference Manual. <https://mc-stan.org>

Vehtari, A., Gelman, A., & Gabry, J. (2017). Practical Bayesian model evaluation using leave-one-out cross-validation and WAIC. *Statistics and Computing*, 27(5), 1413–1432.

WHO (2023). Global Health Observatory data repository: Human African Trypanosomiasis. Organisation Mondiale de la Santé.